

Gabriel Brandão Vechani de Freitas

# **Análise de sensibilidade de um RNN para previsão de estoque hospitalar crítico**

São Paulo

2025

Gabriel Brandão Vechani de Freitas

## **Análise de sensibilidade de um RNN para previsão de estoque hospitalar crítico**

Proposta de Trabalho de Conclusão de Curso  
apresentado ao SENAC Santo Amaro como  
requisito parcial para aprovação na disciplina  
de TCC1 do curso de Ciência da Computação.

SENAC – Serviço Nacional de Aprendizagem Comercial  
Unidade Santo Amaro  
Curso de Ciência da Computação

Orientador: Prof. Douglas Baquião

São Paulo  
2025

# Resumo

Este documento apresenta a proposta inicial do Trabalho de Conclusão de Curso (TCC1) desenvolvido no SENAC Santo Amaro. O objetivo deste trabalho é [descrever brevemente o objetivo principal do TCC]. A justificativa para este estudo baseia-se em [descrever brevemente a justificativa]. A revisão bibliográfica abrange [mencionar os principais tópicos]. Como solução proposta, pretende-se [descrever brevemente a solução]. Este trabalho está organizado em três capítulos que apresentam a introdução ao tema, a revisão bibliográfica que fundamenta a pesquisa, o desenvolvimento com a solução proposta e o cronograma de trabalho, seguidos das referências bibliográficas.

**Palavras-chave:** palavra1. palavra2. palavra3. palavra4. palavra5.

# Sumário

|            |                                                                                                                                                        |           |
|------------|--------------------------------------------------------------------------------------------------------------------------------------------------------|-----------|
| <b>1</b>   | <b>INTRODUÇÃO</b>                                                                                                                                      | <b>4</b>  |
| <b>1.1</b> | <b>Contexto</b>                                                                                                                                        | <b>5</b>  |
| <b>1.2</b> | <b>Justificativa</b>                                                                                                                                   | <b>5</b>  |
| <b>1.3</b> | <b>Objetivo</b>                                                                                                                                        | <b>6</b>  |
| 1.3.1      | Objetivo principal                                                                                                                                     | 6         |
| 1.3.2      | Objetivos secundários                                                                                                                                  | 6         |
| <b>2</b>   | <b>REVISÃO BIBLIOGRÁFICA</b>                                                                                                                           | <b>7</b>  |
| <b>2.1</b> | <b>Referencial teórico</b>                                                                                                                             | <b>7</b>  |
| 2.1.1      | Gestão de Estoques em Ambientes Hospitalares                                                                                                           | 7         |
| 2.1.2      | Redes Neurais Recorrentes e LSTMs para Séries Temporais                                                                                                | 7         |
| 2.1.3      | Previsão de Ruptura e Níveis de Estoque*                                                                                                               | 8         |
| 2.1.4      | Análise de Sensibilidade e Robustez em Modelos de IA                                                                                                   | 8         |
| <b>2.2</b> | <b>Metodologia da pesquisa bibliográfica</b>                                                                                                           | <b>8</b>  |
| <b>2.3</b> | <b>Fundamentos</b>                                                                                                                                     | <b>9</b>  |
| <b>2.4</b> | <b>Trabalhos relacionados</b>                                                                                                                          | <b>9</b>  |
| 2.4.1      | Trabalho 1: Applying Deep Learning and Forecasting Techniques to the Pharmaceutical Supply Chain                                                       | 10        |
| 2.4.2      | Trabalho 2: Predictive Data Analysis: Leveraging RNN and LSTM Techniques for Time Series Dataset                                                       | 11        |
| 2.4.3      | Trabalho 3: Performance analysis of neural network architectures for time series forecasting: A comparative study of RNN, LSTM, GRU, and hybrid models | 12        |
| <b>3</b>   | <b>DESENVOLVIMENTO</b>                                                                                                                                 | <b>14</b> |
| <b>3.1</b> | <b>Solução proposta</b>                                                                                                                                | <b>14</b> |
| <b>3.2</b> | <b>Cronograma de trabalho</b>                                                                                                                          | <b>14</b> |
|            | <b>REFERÊNCIAS</b>                                                                                                                                     | <b>16</b> |

# 1 Introdução

O gerenciamento de estoques é de grande importância para garantir a qualidade e a eficiência nos procedimentos hospitalares, tendo destaque significativo para a qualidade no atendimento e execução de processos. Para os hospitais, os estoques desempenham um papel fundamental, pois viabilizam a prestação de serviços aos pacientes, e principalmente, para a assistência. Segundo [CHIARETTO \(2021\)](#), "Ao realizar os acompanhamentos, controles e monitoramentos de forma lógica e estratégica, o nível de prejuízos e desvios será inferior. Para alcançar este nível na empresa é necessário, principalmente, acompanhamento das rotinas executadas diariamente e auditorias dos processos dos estoques". Uma má gestão da cadeia de abastecimento pode resultar em excesso de insumos, custos fora do orçamento e falta de itens essenciais para o atendimento. Por isso, é essencial administrar e controlar as entradas e saídas de insumos necessários para o atendimento nas instituições, mantendo o funcionamento das operações, mas com foco em menor estoque possível, e é desafiada cotidianamente a manter a previsibilidade de compra e consumo para que não haja desperdícios e nem falta. [Dias \(2024\)](#).

Com o aumento da complexidade dos sistemas de saúde e da demanda por insumos hospitalares, o planejamento de estoques se torna um grande desafio enfrentado pelas instituições de saúde na atualidade, sendo capaz de criar gargalos nos processos e procedimentos dessas instituições. Em um ambiente em que a escassez de recursos e a pressão assistencial são constantes, em conjunto com a imprevisibilidade da demanda, potencializada por eventos epidemiológicos, sazonalidades e picos de ocupação, a previsibilidade e a precisão operacional deixaram de ser diferenciais e tornaram-se vitais. Para [Fialho \(2025\)](#), é justamente nesse ponto que a Inteligência Artificial (IA) vem assumindo um papel transformador, oferecendo um novo patamar de precisão e eficiência na operação logística hospitalar.

Tendo isso como base, este trabalho tem como foco propor analisar a aplicação de uma Rede Neural Recorrente (RNN) na previsão da demanda de itens críticos em estoques hospitalares, com destaque na análise de sensibilidade do modelo de aprendizado de máquina, realizando variações nos parâmetros de entrada. Tendo como escolha de arquitetura a Long Short-Term Memory (LSTM), devido à sua capacidade de aprender dependências de longo prazo em dados sequenciais, com uso de camada de memória. Sendo amplamente aplicável em estoques hospitalares, devido às suas características de demanda por insumos, que podem ser influenciadas por sazonalidades, surtos epidemiológicos e variações no atendimento. O objetivo é compreender se esse tipo de modelo pode contribuir no aprimoramento da eficiência no planejamento de estoques em hospitais, auxiliando na redução de danos tanto por excesso quanto por falta de insumos.

## 1.1 Contexto

Uma abordagem promissora reside na aplicação de técnicas de Deep Learning (DL), que têm demonstrado potencial para otimizar os processos de gestão da cadeia de abastecimento. Alguns estudos têm explorado a utilização de algoritmos de Machine Learning (ML) para resolver problemas de previsão de demanda, apresentando assim alternativas para melhorar a eficiência e a rentabilidade das cadeias de produção farmacêuticas e hospitalares [Espinela \(2025\)](#). No entanto, a aplicação de Redes Neurais Recorrentes (RNN) para previsão de demanda em estoques hospitalares ainda é um campo pouco explorado, especialmente no que diz respeito à análise de sensibilidade do modelo a variações nos parâmetros de entrada.

Os itens críticos hospitalares, como os medicamentos essenciais, os materiais cirúrgicos e os consumíveis de suporte à vida, exigem um elevado nível de controlo, pois a sua indisponibilidade pode levar à interrupção de procedimentos, ao aumento do tempo de internamento ou até a riscos para a vida dos pacientes. Apesar da importância destes itens, muitos sistemas de gestão continuam a utilizar métodos tradicionais de previsão, como médias históricas ou modelos estatísticos simples, que nem sempre conseguem capturar os padrões complexos e dinâmicos da procura.

As RNN têm vasta capacidade para lidar com séries temporais, aprendendo padrões temporais e melhorando a precisão das previsões. No entanto, no contexto hospitalar, a sua utilização com este objetivo não está muito difundida, principalmente na análise de sensibilidade aos parâmetros.

## 1.2 Justificativa

A crescente complexidade na gestão de estoques hospitalares, em conjunto à natureza temporal e variável da demanda por insumos críticos, evidencia a necessidade de abordagens mais robustas para previsão de demanda. Métodos tradicionais, como médias históricas e modelos estatísticos simples, frequentemente não conseguem capturar os padrões dinâmicos presentes nesse tipo de dado, o que justifica a investigação e análise de técnicas de aprendizado de máquina capazes de lidar com essa variabilidade. Nesse sentido, este trabalho propõe a aplicação de uma RNN com arquitetura LSTM, com ênfase na análise de sensibilidade do modelo aos parâmetros de entrada, como forma de ampliar a compreensão sobre o comportamento desses modelos em contextos hospitalares.

Do ponto de vista acadêmico, embora as RNNs e a arquitetura LSTM sejam amplamente estudadas para tarefas de previsão em séries temporais, sua aplicação específica no gerenciamento de estoques hospitalares ainda possui vasta exploração. Mais escassa ainda é a investigação sobre como variações nos parâmetros de entrada afetam o desempenho preditivo nesses cenários. Assim, este estudo contribui para preencher essa lacuna, ofere-

cendo uma análise sistemática do comportamento do modelo frente à variabilidade dos dados.

Do ponto de vista profissional, a imprecisão na previsão de demanda de itens críticos gera consequências diretas para a operação hospitalar. O excesso de insumos representa desperdício financeiro e risco de vencimento de materiais, enquanto a falta pode comprometer procedimentos e colocar em risco a segurança do paciente. Uma ferramenta preditiva mais precisa oferece aos gestores de saúde uma base mais sólida para a tomada de decisões, contribuindo tanto para a eficiência operacional quanto para a qualidade do atendimento.

Por fim, o uso de dados de fontes públicas para o treinamento do modelo reforça o potencial de replicabilidade e escalabilidade da abordagem proposta, tornando-a acessível a diferentes instituições de saúde, independentemente de seu porte ou infraestrutura tecnológica.

## 1.3 Objetivo

Este estudo tem como objetivo avaliar o uso de um RNN para previsões de estoque hospitalar, analisar sensibilidade em seus parâmetros de entrada e como isso afeta os resultados.

### 1.3.1 Objetivo principal

Analisar sensibilidade de um RNN para previsão de estoque hospitalar crítico

### 1.3.2 Objetivos secundários

Os objetivos secundários são desdobramentos do objetivo principal. Eles descrevem as etapas ou ações necessárias para atingir o objetivo principal. Devem ser mensuráveis e verificáveis.

1. Coletar base de dados públicas para treinamento;
2. Identificar e analisar onde será realizado os treinamentos;
3. Implementar algoritmo com técnicas de RNN;

## 2 Revisão Bibliográfica

A revisão bibliográfica tem como finalidade apresentar o embasamento teórico do trabalho, demonstrando o conhecimento do autor sobre o tema e identificando o estado da arte. Este capítulo deve ser organizado por conceitos e temas, construindo uma linha de argumentação que sustente a proposta do trabalho.

### 2.1 Referencial teórico

#### 2.1.1 Gestão de Estoques em Ambientes Hospitalares

A gestão de estoque em ambientes hospitalares é um processo crítico e essencial para garantir a continuidade e qualidade de sistemas de saúde. Como característica hospitalar é lidar com uma grande variedade de itens, que possuem data de validade, alta criticidade e demanda frequentemente variável. Nesse contexto, a falta de determinado item pode comprometer diretamente o atendimento ao paciente, por outro lado o excesso de estoque pode resultar em desperdício e aumento de custos. Sendo assim, o sistema logístico hospitalar deve ser eficientemente planejado e coordenado [Land \(2021, p. 68\)](#).

Em complemento, o uso de tecnologias e técnicas avançadas, como o aprendizado de máquina, tem se mostrado promissor para otimizar a gestão de estoques hospitalares. A capacidade de prever a demanda com maior precisão pode ajudar a reduzir tanto o excesso quanto a falta de insumos, melhorando a eficiência operacional e a qualidade do atendimento ao paciente. No entanto, a aplicação dessas técnicas ainda é um campo em desenvolvimento, especialmente no que diz respeito à análise de sensibilidade dos modelos preditivos utilizados [Sierra Espinel e Suarez Barón \(2025\)](#).

#### 2.1.2 Redes Neurais Recorrentes e LSTMs para Séries Temporais

Uma rede neural recorrente (RNN) é uma rede neural a qual recebe entradas, normalmente de séries temporais, para aprendizado de máquina com a capacidade de gerar conclusões e previsões com base nesses dados. Segundo [Rumelhart, Hinton e Williams \(1986, p. 533\)](#), "Descrevemos um novo procedimento de aprendizagem, a retropropagação, para redes de unidades semelhantes a neurônios. O procedimento ajusta repetidamente os pesos das conexões na rede de modo a minimizar uma medida da diferença entre o vetor de saída real da rede e o vetor de saída desejado.". Podendo ser usada para previsão de demanda, classificação de texto, reconhecimento de fala, entre outros. As RNNs são capazes de capturar dependências temporais em dados sequenciais, o que as torna adequadas para tarefas como previsão de séries temporais, onde os padrões podem se estender



por longos intervalos de tempo. No entanto, as RNNs tradicionais enfrentam dificuldades para aprender dependências de longo prazo devido ao problema do desvanecimento do gradiente, o que limita sua eficácia em tarefas que exigem a retenção de informações por períodos prolongados.

A arquitetura Long Short-Term Memory (LSTM) é um tipo de RNN projetada para lidar com o problema do desvanecimento do gradiente, permitindo que a rede aprenda dependências de longo prazo em dados sequenciais. Contendo uma camada escondida de memória, a LSTM é capaz de manter informações por períodos prolongados, o que a torna especialmente útil para tarefas como previsão de séries temporais, onde os padrões podem se estender por longos intervalos de tempo [Hochreiter e Schmidhuber \(1997\)](#). Podendo ser aplicada em diversos domínios, como o deste estudo que é a previsão de demanda em estoques hospitalares, onde a capacidade de capturar padrões temporais complexos é crucial para melhorar a precisão das previsões e otimizar o gerenciamento de suprimentos.

### 2.1.3 Previsão de Ruptura e Níveis de Estoque\*

### 2.1.4 Análise de Sensibilidade e Robustez em Modelos de IA

## 2.2 Metodologia da pesquisa bibliográfica

Descreva como a pesquisa bibliográfica foi conduzida, incluindo:

- **Bases de dados consultadas:** Google Scholar, IEEE Xplore, ACM Digital Library, SciELO, Periódicos CAPES, entre outras;
- **Palavras-chave utilizadas:**
  - ("critical inventory"OR "critical stock"OR "medical supplies"OR "hospital formulary") AND ("deep learning"OR "neural network"OR "LSTM"OR "RNN") AND ("forecasting"OR "optimization"OR "demand prediction") AND ("hospital"OR "healthcare"OR "pharmaceutical");
  - ("LSTM"OR "GRU"OR "recurrent neural network") AND ("time series forecasting"OR "sequential prediction");
  - ("inventory management"OR "stock forecasting"OR "demand prediction") AND ("hospital"OR "pharmacy"OR "medical supplies"OR "critical stock");
  - ("sensitivity analysis"OR "feature importance"OR "SHAP"OR "Sobol index"OR "ablation study") AND ("neural network"OR "deep learning"OR "machine learning").
- **Crítérios de inclusão e exclusão:** quais critérios foram usados para selecionar ou descartar trabalhos (período, idioma, relevância, tipo de publicação);

- **Período de abrangência:** média de 5 a 6 anos.

A pesquisa bibliográfica foi realizada nas bases Google Scholar, IEEE Xplore, ACM Digital Library, SciELO e Periódicos CAPES, entre outras, utilizando combinações de palavras-chave estruturadas em quatro eixos temáticos: gestão de estoque crítico e insumos hospitalares, redes neurais recorrentes e aprendizado profundo, previsão de demanda em ambientes de saúde, e análise de sensibilidade em modelos de aprendizado de máquina. Entre as expressões empregadas destacam-se termos como "critical inventory", "LSTM", "demand prediction", "hospital pharmacy" e "SHAP", combinados por operadores booleanos para maior precisão na recuperação dos resultados. Foram selecionados artigos publicados predominantemente nos últimos cinco a seis anos, em português e inglês, que abordassem diretamente a aplicação de técnicas de aprendizado profundo — com ênfase em arquiteturas recorrentes como LSTM e GRU — na previsão e otimização de estoques críticos em contextos hospitalares e farmacêuticos. Foram excluídos trabalhos que não apresentassem relação direta com os temas centrais da pesquisa, publicações sem revisão por pares e estudos cujo foco recaísse exclusivamente sobre domínios clínicos sem interface com gestão de suprimentos ou modelagem preditiva.

## 2.3 Fundamentos

Aprofunde os conceitos técnicos que serão utilizados na solução proposta. Diferentemente do referencial teórico (que apresenta conceitos gerais), os fundamentos devem detalhar as tecnologias, algoritmos, frameworks ou metodologias específicas que serão empregados no desenvolvimento.

Por exemplo:

- Se o trabalho utiliza aprendizado de máquina, explique os algoritmos escolhidos (árvores de decisão, redes neurais, SVM, etc.);
- Se o trabalho envolve desenvolvimento de software, descreva as tecnologias (linguagens, frameworks, bancos de dados);
- Se envolve análise de dados, explique as métricas e técnicas estatísticas que serão aplicadas.

Utilize figuras, diagramas e tabelas para ilustrar conceitos quando apropriado.

## 2.4 Trabalhos relacionados

Apresente até **3 trabalhos** que **compartilhem o mesmo foco de resolução de problema** que o seu. O critério principal de seleção é: os trabalhos escolhidos devem ter

tentado resolver o **mesmo problema** (ou um problema muito próximo) ao que você está propondo resolver. Não basta que o trabalho aborde o mesmo tema ou utilize a mesma tecnologia — ele deve ter enfrentado o mesmo desafio prático ou teórico.

**Por que esse critério é importante?** Ao selecionar trabalhos que atacam o mesmo problema, você demonstra que:

- O problema é relevante e já foi reconhecido por outros pesquisadores;
- Existem soluções anteriores, mas com limitações que o seu trabalho pretende superar;
- Seu trabalho não é uma repetição, mas um avanço em relação ao que já foi feito.

Para cada trabalho relacionado, descreva:

1. **Qual problema** o trabalho tentou resolver (e por que é o mesmo problema que o seu);
2. A metodologia ou abordagem utilizada para resolvê-lo;
3. Os principais resultados obtidos;
4. As limitações identificadas na solução proposta;
5. Como o **seu trabalho se diferencia** ou avança em relação a ele.

#### 2.4.1 Trabalho 1: Applying Deep Learning and Forecasting Techniques to the Pharmaceutical Supply Chain

Sierra Espinel e Suarez Barón (2025) abordou o problema de melhorar o atendimento aos pacientes através da disponibilidade de medicamentos, como também contribuir para a eficácia operacional no setor da saúde. Para resolvê-lo, os autores propuseram aplicar técnicas de modelação econométrica e estratégias de aprendizagem profunda (DL), com o objetivo de mensurar e gerar previsões com uma boa precisão. A metodologia utilizada foi MLOps (Operações de Aprendizagem Automática), abrangendo princípios de desenvolvimento de software com práticas de gestão de sistemas, onde foi usado para identificação de modelos e estratégias mais adequadas. Já para o modelo econométrico ARIMA, foram utilizados critérios como o Critério de Informação de Akaike (AIC), o Critério de Informação Bayesiano (BIC) e o Critério de Informação de Hannan-Quinn (HQIC), em conjunto ao teste de Ljung-Box. E para avaliar o aprendizado profundo, foram usados o Erro Absoluto Médio (MAE), o Erro Quadrático Médio (MSE) e o Erro Quadrático Médio Raiz (RMSE).

Os resultados mostraram que os dois modelos, o econométrico ARIMA e o de aprendizado profundo (DL), possuem uma eficácia significativa para previsões de demanda de medicamentos, onde em conjunto podem oferecer uma maior precisão nas previsões,

resultado demonstrado com o uso dos critérios definidos. No entanto, a solução apresenta limitações como a ausência de análise de sensibilidade nos parâmetros de entrada e a não avaliação da robustez dos modelos frente a perturbações nos dados de entrada. O presente trabalho diferencia-se por fazer uso de uma base pública, a qual será tratada para resultar em um grupo de medicamentos essenciais para o sistema de saúde, e por aplicar testes nos parâmetros de entrada para avaliar como o modelo de aprendizagem de máquina se comporta frente a essas variações.

### 2.4.2 Trabalho 2: Predictive Data Analysis: Leveraging RNN and LSTM Techniques for Time Series Dataset

[Agarwal et al. \(2024\)](#) abordou o problema de prever valores futuros de cotações no mercado de ações. Para resolvê-lo, os autores propuseram utilizar Redes Neurais Recorrentes (RNN) e Memória de Longo Prazo (LSTM) para gerar previsões a partir de um conjunto de dados, superando o problema do desvanecimento do gradiente com o uso da arquitetura LSTM. A metodologia utilizada foi estruturar a solução em módulos e classes, sendo eles:

- Módulo de pré-processamento de dados: inclui as funções para carregar, limpar e normalizar os dados relativos aos preços das ações;
- Módulo de arquitetura do modelo: inclui as funções para construir os modelos RNN e LSTM;
- Módulo de treino: inclui as funções para treinar os modelos com base nos dados históricos;
- Módulo de previsão: inclui as funções para efetuar previsões sobre os dados de teste e avaliar o desempenho dos modelos.

Para construir os modelos, os autores utilizaram Python e as bibliotecas Keras e TensorFlow. Para normalizar os dados, foi utilizado o `MinMaxScaler` da biblioteca `sklearn`. A separação dos conjuntos de treino e teste foi de 85:15, ou seja, 85% dos dados foram utilizados para treinar o modelo LSTM e 15% para teste, com janelas de 100 pontos de dados. O Erro Quadrático Médio Raiz (RMSE), as medidas R-quadrado e as métricas de acurácia foram utilizados para avaliar o desempenho dos modelos.

Os resultados mostraram que o modelo LSTM apresentou desempenho superior ao modelo RNN: o modelo RNN, após 100 épocas, obteve uma acurácia de 97,12% nos dados de treino e de 81,01% nos dados de teste, enquanto o modelo LSTM, aplicado ao mesmo conjunto de dados, alcançou 98,10% nos dados de treino e 91,97% nos dados de teste. No entanto, assim como o trabalho anterior, a solução apresenta limitações como a ausência de análise de sensibilidade nos parâmetros de entrada, a não avaliação da robustez dos modelos frente a perturbações nos dados e a aplicação restrita ao domínio financeiro, sem

contemplar contextos hospitalares. O presente trabalho diferencia-se por aplicar métodos de análise de sensibilidade e avaliação da robustez em um modelo preditivo voltado à gestão de estoques hospitalares críticos.

### 2.4.3 Trabalho 3: Performance analysis of neural network architectures for time series forecasting: A comparative study of RNN, LSTM, GRU, and hybrid models

[Yunita et al. \(2025\)](#) abordou o problema de avaliar o desempenho de nove arquiteturas de redes neurais para previsão de séries temporais, nomeadamente RNN, LSTM, GRU, RNN-LSTM, RNN-GRU, LSTM-RNN, GRU-RNN, LSTM-GRU e GRU-LSTM. Para resolvê-lo, os autores propuseram uma avaliação baseada no método de Monte Carlo (MC), com o objetivo de garantir a confiabilidade dos resultados frente à variabilidade decorrente da inicialização aleatória dos pesos. A metodologia utilizada consistiu em selecionar três conjuntos de dados nas áreas da astronomia, cuidados de saúde e maquinaria, realizar uma análise exploratória de dados (EDA) como etapa preliminar de avaliação estatística e de qualidade, desenvolver as diferentes arquiteturas de redes neurais e, por fim, avaliar os modelos por meio de 100 iterações de Monte Carlo, utilizando as métricas de Erro Absoluto Médio (MAE), Erro Percentual Absoluto Médio (MAPE) e Erro Quadrático Médio (RMSE).

Os resultados mostraram que, pelo teste de Friedman, não houve diferença estatisticamente significativa entre as arquiteturas avaliadas. Esse resultado pode ter sido influenciado por fatores como a dimensão limitada da amostra, com apenas três conjuntos de dados para avaliação, e o possível mascaramento das diferenças de desempenho pelo ruído experimental. Ainda assim, os padrões de desempenho consistentes observados em todos os conjuntos de dados sugerem potenciais vantagens práticas para as arquiteturas híbridas baseadas em LSTM, especialmente as configurações LSTM-RNN e LSTM-GRU. No entanto, a solução apresenta limitações como o número reduzido de conjuntos de dados utilizados na avaliação, a ausência de investigação sobre o impacto de perturbações nos parâmetros de entrada sobre o desempenho preditivo e a não aplicação dos modelos em contextos hospitalares. O presente trabalho diferencia-se por aplicar uma análise de sensibilidade sistemática nos parâmetros de entrada de um modelo LSTM voltado à previsão de estoques hospitalares críticos, investigando como variações nesses parâmetros afetam o desempenho preditivo, parte não explorada por [Yunita et al. \(2025\)](#), que avaliam a robustez apenas em relação à inicialização aleatória dos pesos, sem considerar perturbações nos dados de entrada.

Uma tabela comparativa ajuda a sintetizar as diferenças entre os trabalhos:

Tabela 1 – Comparação entre trabalhos relacionados

| Critério   | Trabalho 1                       | Trabalho 2                                       | Trabalho 3                                   | Este trabalho                                                    |
|------------|----------------------------------|--------------------------------------------------|----------------------------------------------|------------------------------------------------------------------|
| Objetivo   | Previsão de demanda farmacêutica | Previsão de cotações de ações                    | Comparação de arquiteturas RNN, LSTM e GRU   | Análise de sensibilidade de LSTM para estoque hospitalar crítico |
| Tecnologia | ARIMA + DL (MLOps)               | RNN + LSTM (Keras/TensorFlow)                    | RNN, LSTM, GRU, modelos híbridos             | LSTM + análise de sensibilidade                                  |
| Validação  | MAE, MSE, RMSE, AIC, BIC         | RMSE, $R^2$ , acurácia                           | MAE, MAPE, RMSE (Monte Carlo)                | [método]                                                         |
| Limitação  | Sem análise de sensibilidade     | Sem análise de sensibilidade; domínio financeiro | Poucos datasets; sem perturbações na entrada | —                                                                |

Fonte: Elaborado pelo autor (2025)

## 3 Desenvolvimento

Neste capítulo, apresenta-se a solução proposta para o problema identificado, bem como o cronograma de trabalho previsto para o desenvolvimento completo do projeto no TCC2.

### 3.1 Solução proposta

Descreva detalhadamente a solução que será desenvolvida para resolver o problema apresentado na introdução. A descrição deve incluir:

- **Visão geral da solução:** o que será desenvolvido (sistema, aplicativo, modelo, ferramenta, etc.);
- **Arquitetura:** como os componentes da solução se organizam e interagem;
- **Tecnologias e ferramentas:** quais linguagens, frameworks, bibliotecas, bancos de dados e ambientes serão utilizados, e por que foram escolhidos;
- **Funcionalidades principais:** o que a solução fará para atender aos objetivos;
- **Metodologia de desenvolvimento:** qual abordagem será utilizada (ágil, cascata, prototipação, etc.);
- **CrITÉrios de validação:** como será medido o sucesso da solução (métricas, testes, avaliação com usuários, etc.).

Utilize diagramas, fluxogramas ou mockups para ilustrar a solução. Exemplo de descrição de arquitetura:

*A solução proposta consiste em uma aplicação web composta por três camadas: front-end desenvolvido em React.js, back-end em Node.js com Express, e banco de dados PostgreSQL. A comunicação entre front-end e back-end será feita por meio de uma API REST.*


### 3.2 Cronograma de trabalho

O cronograma a seguir apresenta, no formato de diagrama de Gantt, as atividades previstas para o desenvolvimento do TCC2, distribuídas ao longo das semanas do semestre.

**Instruções para personalização do cronograma:**

- Ajuste o número de semanas conforme o calendário acadêmico do semestre;
- Modifique as atividades de acordo com as etapas do seu projeto;

Figura 1 – Cronograma de atividades – Diagrama de Gantt



Fonte: Elaborado pelo autor (2025)

- Os marcos (*milestones*) indicam entregas importantes — adapte-os às datas de avaliação;
- As setas entre atividades indicam dependências — uma atividade só inicia após a conclusão da anterior;
- Utilize o diagrama como ferramenta de acompanhamento: atualize-o a cada reunião com o orientador.



# Referências

AGARWAL, H. et al. Predictive data analysis: Leveraging rnn and lstm techniques for time series dataset. *Procedia Computer Science*, v. 235, p. 979–989, 2024. ISSN 1877-0509. International Conference on Machine Learning and Data Engineering (ICMLDE 2023). Disponível em: <<https://www.sciencedirect.com/science/article/pii/S1877050924007695>>. 11

CHIARETTO, S. Um estudo sobre os impactos da gestão de estoques nas instituições hospitalares. *Revista Científica Faculdade Unimed*, 2021. 4

DIAS, P. S. F. F. e William de S. Previsão de demanda: Ferramenta auxiliadora na tomada de decisão no processo de aquisição de insumos em uma farmácia hospitalar localizada em palmas-to. *humanidadeseinovacao*, 2024. 4

ESPINELA, M. J. S. B. A. I. S. Applying deep learning and forecasting techniques to the pharmaceutical supply chain. *ScienceDirect*, v. 253, p. 2792–2800, 2025. 5

FIALHO, T. Previsibilidade e precisão: Ia na gestão logística da saúde. *medicinasa*, 2025. 4

HOCHREITER, S.; SCHMIDHUBER, J. Long short-term memory. 1997. 8

LAND, C. L. de Souza e M. Estratégias de gestão de estoque hospitalar em organizações públicas no brasil: Um estudo de caso. *Revista de Administração Hospitalar e Inovação em Saúde (RAHIS)*, v. 17, n. 3, 2021. 7

RUMELHART, D. E.; HINTON, G. E.; WILLIAMS, R. J. Learning representations by back-propagating errors. *Nature*, 1986. 7

Sierra Espinel, A. I.; Suarez Barón, M. J. Applying deep learning and forecasting techniques to the pharmaceutical supply chain. *Procedia Computer Science*, v. 253, p. 2791–2800, 2025. ISSN 1877-0509. 6th International Conference on Industry 4.0 and Smart Manufacturing. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S1877050925003461>>. 7, 10

YUNITA, A. et al. Performance analysis of neural network architectures for time series forecasting: A comparative study of rnn, lstm, gru, and hybrid models. *MethodsX*, v. 15, p. 103462, 2025. ISSN 2215-0161. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S2215016125003073>>. 12