

Gabriel Brandão Vechani de Freitas

Análise de sensibilidade de um RNN para previsão de estoque hospitalar crítico

São Paulo

2025

Gabriel Brandão Vechani de Freitas

Análise de sensibilidade de um RNN para previsão de estoque hospitalar crítico

Proposta de Trabalho de Conclusão de Curso
apresentado ao SENAC Santo Amaro como
requisito parcial para aprovação na disciplina
de TCC1 do curso de Ciência da Computação.

SENAC – Serviço Nacional de Aprendizagem Comercial
Unidade Santo Amaro
Curso de Ciência da Computação

Orientador: Prof. Douglas Baquião

São Paulo
2025

Resumo

Este documento apresenta a proposta inicial do Trabalho de Conclusão de Curso (TCC1) desenvolvido no SENAC Santo Amaro. O objetivo deste trabalho é [descrever brevemente o objetivo principal do TCC]. A justificativa para este estudo baseia-se em [descrever brevemente a justificativa]. A revisão bibliográfica abrange [mencionar os principais tópicos]. Como solução proposta, pretende-se [descrever brevemente a solução]. Este trabalho está organizado em três capítulos que apresentam a introdução ao tema, a revisão bibliográfica que fundamenta a pesquisa, o desenvolvimento com a solução proposta e o cronograma de trabalho, seguidos das referências bibliográficas.

Palavras-chave: palavra1. palavra2. palavra3. palavra4. palavra5.

Sumário

1	INTRODUÇÃO	4
1.1	Contexto	5
1.2	Justificativa	5
1.3	Objetivo	6
1.3.1	Objetivo principal	6
1.3.2	Objetivos secundários	7
2	REVISÃO BIBLIOGRÁFICA	8
2.1	Referencial teórico	8
2.1.1	Gestão de Estoques em Ambientes Hospitalares	8
2.1.2	Redes Neurais Recorrentes e LSTMs para Séries Temporais	8
2.1.3	Previsão de Ruptura e Níveis de Estoque*	9
2.1.4	Análise de Sensibilidade e Robustez em Modelos de IA	10
2.1.5	Pré-processamento de Séries Temporais e Imputação de Dados	11
2.1.6	Métricas de Desempenho e Erro	11
2.1.7	Particularidades da Demanda Hospitalar	11
2.2	Metodologia da pesquisa bibliográfica	11
2.3	Trabalhos relacionados	12
2.3.1	Trabalho 1: Applying Deep Learning and Forecasting Techniques to the Pharmaceutical Supply Chain	12
2.3.2	Trabalho 2: Predictive Data Analysis: Leveraging RNN and LSTM Techniques for Time Series Dataset	13
2.3.3	Trabalho 3: Performance analysis of neural network architectures for time series forecasting: A comparative study of RNN, LSTM, GRU, and hybrid models	14
3	DESENVOLVIMENTO	16
3.1	Solução proposta	16
3.2	Cronograma de trabalho	16
	REFERÊNCIAS	18

1 Introdução

O gerenciamento de estoques é de grande importância para garantir a qualidade e a eficiência nos procedimentos hospitalares, tendo destaque significativo para a qualidade no atendimento e execução de processos. Para os hospitais, os estoques desempenham um papel fundamental, pois viabilizam a prestação de serviços aos pacientes, e principalmente, para a assistência. Ao realizar acompanhamentos de forma lógica e estratégica há uma tendência de o nível de prejuízos e desvios ser inferior. Para que a empresa ou instituição alcance um bom desempenho, é necessário, principalmente, o acompanhamento das rotinas executadas diariamente e a auditoria dos processos de estoque (CHIARETTO (2021)). Uma má gestão da cadeia de abastecimento pode resultar em excesso de insumos, custos fora do orçamento e falta de itens essenciais para o atendimento. Por isso, é essencial administrar e controlar as entradas e saídas de insumos necessários para o atendimento nas instituições, mantendo o funcionamento das operações, mas com foco em menor estoque possível. Neste contexto, a instituição é desafiada cotidianamente a manter a previsibilidade de compra e consumo para que não haja desperdícios e nem falta (Dias (2024)).

Com o aumento da complexidade dos sistemas de saúde e da demanda por insumos hospitalares, o planejamento de estoques se torna um grande desafio enfrentado pelas instituições de saúde na atualidade, sendo capaz de criar gargalos nos processos e procedimentos dessas instituições. Em um ambiente em que a escassez de recursos e a pressão assistencial são constantes, em conjunto com a imprevisibilidade da demanda, potencializada por eventos epidemiológicos, sazonalidades e picos de ocupação, a previsibilidade e a precisão operacional deixaram de ser diferenciais e tornaram-se vitais. Para (Fialho (2025)), é justamente nesse ponto que a Inteligência Artificial (IA) vem assumindo um papel transformador, oferecendo um novo patamar de precisão e eficiência na operação logística hospitalar.

Tendo isso como base, este trabalho tem como foco analisar a aplicação de uma Rede Neural Recorrente (RNN) na previsão da demanda de itens críticos em estoques hospitalares, com destaque na análise de sensibilidade do modelo de aprendizado de máquina, realizando variações nos parâmetros de entrada observando sua relevância no contexto aplicado medido com SHAP e LIME. Tendo como escolha de arquitetura a Long Short-Term Memory (LSTM), devido à sua capacidade de aprender dependências de longo prazo em dados sequenciais, com uso de camada de memória. Sendo amplamente aplicável em estoques hospitalares, devido às suas características de demanda por insumos, que podem ser influenciadas por sazonalidades, surtos epidemiológicos e variações no atendimento. O objetivo é compreender se esse tipo de modelo pode contribuir no aprimoramento da eficiência no planejamento de estoques em hospitais, auxiliando na redução de danos tanto por excesso quanto por falta de insumos.

1.1 Contexto

Uma abordagem promissora reside na aplicação de técnicas de Deep Learning (DL), que têm demonstrado potencial para otimizar os processos de gestão da cadeia de abastecimento. Alguns estudos têm explorado a utilização de algoritmos de Machine Learning (ML) para resolver problemas de previsão de demanda, apresentando assim alternativas para melhorar a eficiência e a rentabilidade das cadeias de produção farmacêuticas e hospitalares ([Sierra Espinel e Suarez Barón \(2025\)](#)). No entanto, a aplicação de Redes Neurais Recorrentes (RNN) para previsão de demanda em estoques hospitalares ainda é um campo pouco explorado, especialmente no que diz respeito à análise de sensibilidade do modelo a variações nos parâmetros de entrada.

Os itens críticos hospitalares, como os medicamentos essenciais, os materiais cirúrgicos e os consumíveis de suporte à vida exigem um elevado nível de controle, pois a sua indisponibilidade pode levar à interrupção de procedimentos, ao aumento do tempo de internamento ou até a riscos para a vida dos pacientes. Apesar da importância destes itens, muitos sistemas de gestão continuam a utilizar métodos tradicionais de previsão, como médias históricas ou modelos estatísticos simples, que nem sempre conseguem capturar os padrões complexos e dinâmicos da procura.

As RNN têm vasta capacidade para lidar com séries temporais, aprendendo padrões temporais e melhorando a precisão das previsões ([Agarwal et al. \(2024\)](#)). No entanto, no contexto hospitalar, a sua utilização com este objetivo não está muito difundida, principalmente na análise de sensibilidade aos parâmetros.

1.2 Justificativa

A previsão de demanda por insumos críticos em ambientes hospitalares apresenta desafios particulares, decorrentes da natureza temporal, variável e muitas vezes imprevisível desse tipo de consumo. Métodos tradicionais, como médias históricas e modelos estatísticos simples, mostram-se limitados na captura dos padrões dinâmicos que caracterizam essas séries, o que motiva a investigação de técnicas de aprendizado de máquina mais adequadas a esse cenário ([Baráth, Veres e Bányai \(2026\)](#)). Nesse contexto, este trabalho propõe a aplicação de uma RNN com arquitetura LSTM para a previsão de estoques hospitalares críticos, com ênfase na análise de sensibilidade do modelo frente a variações em seus parâmetros de entrada, buscando compreender de forma sistemática como tais variações influenciam seu desempenho preditivo.

Do ponto de vista acadêmico, embora as RNNs e a arquitetura LSTM sejam amplamente investigadas em tarefas de previsão de séries temporais, sua aplicação ao gerenciamento de estoques hospitalares ainda é pouco explorada na literatura, conforme evidenciado pela escassez de estudos identificados nas bases consultadas que combinam esses dois eixos. Mais

incipiente ainda é a investigação sobre o impacto que variações nos parâmetros de entrada exercem sobre o desempenho preditivo nesse domínio específico, lacuna observada nos trabalhos relacionados analisados nesta pesquisa, que avaliam o desempenho de modelos LSTM sem submetê-los a perturbações controladas em suas entradas. Compreender esse comportamento é relevante porque dados hospitalares estão frequentemente sujeitos a ruídos, registros incompletos e oscilações abruptas decorrentes de eventos epidemiológicos, o que torna a robustez do modelo um critério tão importante quanto sua acurácia média. Assim, este estudo contribui para preencher essa lacuna ao oferecer uma análise sistemática da sensibilidade do modelo à variabilidade dos dados, ampliando a compreensão sobre seu comportamento em cenários hospitalares reais.

Do ponto de vista profissional, a imprecisão na previsão de demanda por itens críticos impacta diretamente a operação hospitalar e gera consequências em duas frentes. Por um lado, o excesso de insumos resulta em desperdício financeiro e em risco de perda de materiais por vencimento. Por outro lado, a falta pode comprometer a continuidade de procedimentos assistenciais e colocar em risco a segurança do paciente. Uma ferramenta preditiva mais precisa e cujo comportamento seja conhecido frente a variações nos dados oferece aos gestores de saúde uma base mais sólida para a tomada de decisão, contribuindo simultaneamente para a eficiência operacional e para a qualidade do atendimento prestado.

Por fim, o uso de dados de fontes públicas para o treinamento do modelo reforça o potencial de replicabilidade e escalabilidade da abordagem proposta, tornando-a acessível a diferentes instituições de saúde, independentemente de seu porte ou infraestrutura tecnológica.

1.3 Objetivo

Este estudo tem como objetivo avaliar o uso de uma Rede Neural Recorrente (RNN), com arquitetura LSTM, para a previsão de demanda de itens críticos em estoques hospitalares, investigando de forma sistemática como variações controladas em seus parâmetros de entrada e hiperparâmetros impactam o desempenho preditivo do modelo.

1.3.1 Objetivo principal

Analisar a sensibilidade de um modelo LSTM aplicado à previsão de demanda de itens críticos em estoques hospitalares, mensurando o impacto de variações controladas em parâmetros de entrada (tamanho da janela temporal, presença de ruído nas séries e proporção de valores faltantes) e em hiperparâmetros estruturais (número de camadas, número de unidades, taxa de aprendizado e taxa de regularização) sobre o desempenho preditivo do modelo, avaliado por meio das métricas Erro Absoluto Médio (MAE), Erro Quadrático Médio Raiz (RMSE) e Erro Percentual Absoluto Médio (MAPE), bem como pela variabilidade dessas métricas frente às perturbações aplicadas.

1.3.2 Objetivos secundários

Com base no objetivo principal forá definido os objetivos secundários, onde tais descrevem as etpas e ações necessária para realizar o objetivo.

1. Investigar, na literatura especializada, as principais técnicas de análise de sensibilidade aplicáveis a modelos de aprendizado profundo voltados a séries temporais, identificando aquelas mais adequadas ao contexto da previsão de estoques hospitalares críticos;
2. Selecionar e caracterizar uma base de dados pública de consumo hospitalar adequada ao escopo do estudo, descrevendo seus atributos, limitações e o tratamento necessário (limpeza, normalização e segmentação em conjuntos de treino, validação e teste) para sua utilização no treinamento do modelo;
3. Definir o ambiente computacional de experimentação, justificando a escolha das ferramentas, bibliotecas (como TensorFlow ou PyTorch) e recursos de hardware adotados, de modo a garantir a reprodutibilidade dos experimentos e o controle sobre os fatores externos ao modelo;
4. Implementar e treinar um modelo LSTM de referência (baseline) para previsão de demanda de itens críticos, documentando sua arquitetura, processo de treinamento e desempenho preditivo nas métricas adotadas, de modo a estabelecer um ponto de comparação para os experimentos de sensibilidade;
5. Definir e aplicar um protocolo experimental de análise de sensibilidade, como fazer uso de SHAP e LIME, aplicando perturbações controladas aos parâmetros de entrada e hiperparâmetros previamente definidos e registrando, de forma sistemática, o desempenho do modelo sob cada cenário;
6. Analisar e discutir os resultados obtidos, identificando quais parâmetros exercem maior influência sobre o desempenho preditivo do modelo e quais cenários representam maior risco para a aplicação prática em ambientes hospitalares, apontando limitações do estudo e direções para trabalhos futuros.

2 Revisão Bibliográfica

Esta seção tem como objetivo apresentar o embasamento teórico do trabalho, organizando os principais conceitos e temas de forma a construir uma linha de argumentação que sustente a proposta desenvolvida.

2.1 Referencial teórico

2.1.1 Gestão de Estoques em Ambientes Hospitalares

A gestão de estoque em ambientes hospitalares é um processo crítico e essencial para garantir a continuidade e qualidade de sistemas de saúde. Como característica hospitalar é lidar como uma grande variedade de itens, que possuem data de validade, alta criticidade e demanda frequentemente variável. Nesse contexto, a falta de determinado item pode comprometer diretamente o atendimento ao paciente. Por outro lado o excesso de estoque pode resultar em desperdício e aumento de custos. Sendo assim, o sistema logístico hospitalar deve ser eficientemente planejado e coordenado, conforme relatado por ([Land \(2021, p. 68\)](#))).

Em complemento, o uso de tecnologias e técnicas avançadas, como o aprendizado de máquina, tem se mostrado promissor para otimizar a gestão de estoques hospitalares. A capacidade de prever a demanda com maior precisão pode ajudar a reduzir tanto o excesso quanto a falta de insumos, melhorando a eficiência operacional e a qualidade do atendimento ao paciente. No entanto, a aplicação dessas técnicas ainda é um campo em desenvolvimento, especialmente no que diz respeito à análise de sensibilidade dos modelos preditivos utilizados, assim como descrito por ([Sierra Espinel e Suarez Barón \(2025\)](#))).

2.1.2 Redes Neurais Recorrentes e LSTMs para Séries Temporais

Uma rede neural recorrente (RNN) é um tipo de rede neural projetada para processar entradas sequenciais, geralmente séries temporais, sendo amplamente utilizada em aprendizado de máquina pela sua capacidade de gerar conclusões e previsões com base nesses dados. É um procedimento de aprendizagem, a retropropagação, para redes de unidades semelhantes a neurônios. O procedimento ajusta repetidamente os pesos das conexões na rede de modo a minimizar uma medida da diferença entre o vetor de saída real da rede e o vetor de saída desejado, segundo ([Rumelhart, Hinton e Williams \(1986\)](#))). Podendo ser usada para previsão de demanda, classificação de texto, reconhecimento de fala, entre outros. As RNNs são capazes de capturar dependências temporais em dados sequenciais, o que as torna adequadas para tarefas como previsão de séries temporais, onde os padrões

podem se estender por longos intervalos de tempo. No entanto, as RNNs tradicionais enfrentam dificuldades para aprender dependências de longo prazo devido ao problema do desvanecimento do gradiente, o que limita sua eficácia em tarefas que exigem a retenção de informações por períodos prolongados.

A arquitetura Long Short-Term Memory (LSTM) é um tipo de RNN projetada para lidar com o problema do desvanecimento do gradiente, permitindo que a rede aprenda dependências de longo prazo em dados sequenciais. Contendo uma camada escondida de memória, a LSTM é capaz de manter informações por períodos prolongados, o que a torna especialmente útil para tarefas como previsão de séries temporais, onde os padrões podem se estender por longos intervalos de tempo ([Hochreiter e Schmidhuber \(1997\)](#)). Podendo ser aplicada em diversos domínios, como o deste estudo que é a previsão de demanda em estoques hospitalares, onde a capacidade de capturar padrões temporais complexos é crucial para melhorar a precisão das previsões e otimizar o gerenciamento de suprimentos.

2.1.3 Previsão de Ruptura e Níveis de Estoque*

A previsão de ruptura de estoque (stockout), refere-se à antecipação do momento em que o nível de um item disponível torna-se insuficiente para atender à demanda. Em contextos hospitalares, esse evento é particularmente crítico, pois pode comprometer a continuidade de procedimentos assistenciais, ou até mesmo colocar em risco a segurança do paciente. Para mitigar esse risco, a literatura de gestão de operações estabelece dois conceitos fundamentais que orientam a política de reposição: o estoque de segurança (safety stock), entendido como a quantidade adicional mantida em estoque para absorver variações na demanda e nos prazos de entrega, e o ponto de pedido (reorder point), definido como o nível de estoque a partir do qual uma nova ordem de reposição deve ser emitida, calculado tradicionalmente como a soma entre a demanda esperada durante o tempo de espera e o estoque de segurança. A precisão desses parâmetros depende diretamente da qualidade da previsão de demanda subjacente, uma vez que estimativas imprecisas geram tanto excesso de estoque, com custos financeiros e risco de vencimento, quanto rupturas, com prejuízos operacionais e clínicos.

Tradicionalmente, esses cálculos têm sido realizados por meio de fórmulas estatísticas que assumem distribuições conhecidas da demanda e do tempo de espera, o que pode ser limitante em ambientes hospitalares marcados por demandas intermitentes, sazonalidades e eventos epidemiológicos. Para superar essas restrições, estudos recentes têm proposto integrar modelos de aprendizado profundo, especialmente arquiteturas recorrentes como a LSTM, ao processo de previsão de demanda que alimenta o cálculo do estoque de segurança e do ponto de pedido. Trabalhos como o de ([Seyedan, Mafakheri e Wang \(2023\)](#)) demonstram que abordagens baseadas em Aprendizado em Conjunto (ensemble) com LSTM podem melhorar a acurácia das previsões e, conseqüentemente, permitir a definição dinâmica dos níveis de estoque sob diferentes cenários de tempo de espera. Entretanto,

conforme apontam (Baráth, Veres e Bányai (2026)), em séries com baixa razão sinal-ruído, modelos LSTM treinados com função de perda quadrática, Erro Quadrático Médio (MSE), tendem a suavizar picos de demanda, o que pode resultar em subestimação sistemática e em cálculos enviesados do estoque de segurança, aumentando o risco de ruptura. Esse comportamento reforça a necessidade de avaliar não apenas a acurácia média do modelo, mas também sua sensibilidade frente a variações nas entradas, especialmente quando suas previsões alimentam decisões logísticas com impacto direto sobre a operação hospitalar.

2.1.4 Análise de Sensibilidade e Robustez em Modelos de IA

A análise de sensibilidade em modelos de inteligência artificial consiste no estudo sistemático de como variações controladas em parâmetros ou entradas do modelo afetam suas saídas, sendo um instrumento essencial para avaliar a estabilidade, a interpretabilidade e a confiabilidade de soluções baseadas em aprendizado profundo. No contexto de redes neurais, essa análise pode ser conduzida em duas frentes principais: a sensibilidade a hiperparâmetros, que examina o impacto de escolhas estruturais, como número de camadas, taxa de aprendizado, função de ativação e dimensão de janela temporal sobre o desempenho preditivo (Novello et al. (2022)); e a sensibilidade aos dados de entrada, que avalia a resposta do modelo frente a perturbações aplicadas às variáveis da série temporal, sejam elas ruídos, valores faltantes ou alterações em variáveis específicas (Wang (2024)). Já o conceito de robustez é frequentemente associado à capacidade do modelo de manter desempenho estável diante dessas perturbações, sendo, portanto, uma propriedade verificada a partir da análise de sensibilidade. Em séries temporais, essas avaliações são particularmente relevantes, pois pequenas variações em parâmetros como tamanho da janela de entrada ou taxa de regularização podem alterar significativamente a capacidade do modelo de capturar padrões temporais complexos.

Entre as técnicas mais utilizadas para conduzir esse tipo de análise, destacam-se métodos baseados em perturbação direta das entradas com medição da variação na saída, conforme descrito por (Guan (2024)), índices estatísticos como o critério HSIC (Hilbert-Schmidt Independence Criterion) aplicado à exploração do espaço de hiperparâmetros, conforme citado por (Novello et al. (2022)), e abordagens de explicabilidade como SHAP (SHapley Additive exPlanations). Quando aplicadas a modelos LSTM, essas técnicas permitem identificar quais janelas temporais e quais variáveis exercem maior influência sobre a previsão, fornecendo subsídios para a interpretação e o aprimoramento do modelo, conforme explicado por (Sen (2025)). Além disso, estudos de ablação, em que componentes do modelo ou subconjuntos de features são removidos para observar o impacto no desempenho, complementam a avaliação ao expor possíveis dependências críticas. No contexto da previsão de estoques hospitalares, a aplicação dessas técnicas é especialmente pertinente, pois os dados costumam apresentar ruídos, registros incompletos e padrões irregulares decorrentes de eventos epidemiológicos, fatores que tornam a análise de sensibilidade

um requisito tanto técnico quanto operacional para garantir confiabilidade nas decisões logísticas baseadas no modelo.

2.1.5 Pré-processamento de Séries Temporais e Imputação de Dados

2.1.6 Métricas de Desempenho e Erro

2.1.7 Particularidades da Demanda Hospitalar

2.2 Metodologia da pesquisa bibliográfica

A seguir são apresentados os principais tópicos que nortearam a condução desta pesquisa:

- **Bases de dados consultadas:** Google Scholar, IEEE Xplore, ACM Digital Library, SciELO, Periódicos CAPES, entre outras;
- **Palavras-chave utilizadas:**
 - ("critical inventory"OR "critical stock"OR "medical supplies"OR "hospital formulary") AND ("deep learning"OR "neural network"OR "LSTM"OR "RNN") AND ("forecasting"OR "optimization"OR "demand prediction") AND ("hospital"OR "healthcare"OR "pharmaceutical");
 - ("LSTM"OR "GRU"OR "recurrent neural network") AND ("time series forecasting"OR "sequential prediction");
 - ("inventory management"OR "stock forecasting"OR "demand prediction") AND ("hospital"OR "pharmacy"OR "medical supplies"OR "critical stock");
 - ("sensitivity analysis"OR "feature importance"OR "SHAP"OR "Sobol index"OR "ablation study") AND ("neural network"OR "deep learning"OR "machine learning").
- **Critérios de inclusão e exclusão:** Os critérios de inclusão adotados para a seleção dos trabalhos foram: publicações nos idiomas português e inglês; trabalhos do tipo científico, como artigos, dissertações; publicações dos últimos 5 a 6 anos, garantindo a atualidade das referências; e relevância acadêmica, priorizando trabalhos publicados em periódicos indexados, com revisão por pares e alinhados à temática central da pesquisa;
- **Período de abrangência:** média de 5 a 6 anos.

A pesquisa bibliográfica foi realizada nas bases Google Scholar, IEEE Xplore, ACM Digital Library, SciELO e Periódicos CAPES, entre outras, utilizando combinações de

palavras-chave estruturadas em quatro eixos temáticos: gestão de estoque crítico e insumos hospitalares, redes neurais recorrentes e aprendizado profundo, previsão de demanda em ambientes de saúde, e análise de sensibilidade em modelos de aprendizado de máquina. Entre as expressões empregadas destacam-se termos como "critical inventory", "LSTM", "demand prediction", "hospital pharmacy", "SHAP" e "LIME", combinados por operadores booleanos para maior precisão na recuperação dos resultados. Foram selecionados artigos publicados predominantemente nos últimos cinco a seis anos, em português e inglês, que abordassem diretamente a aplicação de técnicas de aprendizado profundo — com ênfase em arquiteturas recorrentes como LSTM e GRU — na previsão e otimização de estoques críticos em contextos hospitalares e farmacêuticos. Foram excluídos trabalhos que não apresentassem relação direta com os temas centrais da pesquisa, publicações sem revisão por pares e estudos cujo foco recaísse exclusivamente sobre domínios clínicos sem interface com gestão de suprimentos ou modelagem preditiva.

2.3 Trabalhos relacionados

Nesta seção serão apresentados 3 trabalhos selecionados que têm como base o uso de redes neurais recorrentes (RNN/LSTM), aprendizado de máquina e séries temporais, além da análise crítica de seus respectivos resultados. Os trabalhos foram escolhidos seguindo os critérios citados em 2.2, contribuindo para a compreensão do estado da arte na área. A seguir, é apresentado um resumo individual de cada um dos trabalhos pesquisados, descrevendo seus objetivos, metodologias adotadas e os principais desafios enfrentados ao longo de seu desenvolvimento.

2.3.1 Trabalho 1: Applying Deep Learning and Forecasting Techniques to the Pharmaceutical Supply Chain

(Sierra Espinel e Suarez Barón (2025)) abordou o problema de melhorar o atendimento aos pacientes através da disponibilidade de medicamentos, como também contribuir para a eficácia operacional no setor da saúde. Para resolvê-lo, os autores propuseram aplicar técnicas de modelação econométrica e estratégias de aprendizagem profunda (DL), com o objetivo de mensurar e gerar previsões com uma boa precisão. A metodologia utilizada foi MLOps (Operações de Aprendizagem Automática), abrangendo princípios de desenvolvimento de software com práticas de gestão de sistemas, onde foi usado para identificação de modelos e estratégias mais adequadas. Já para o modelo econométrico ARIMA, foram utilizados critérios como o Critério de Informação de Akaike (AIC), o Critério de Informação Bayesiano (BIC) e o Critério de Informação de Hannan-Quinn (HQIC), em conjunto ao teste de Ljung-Box. E para avaliar o aprendizado profundo,

foram usados o Erro Absoluto Médio (MAE), o Erro Quadrático Médio (MSE) e o Erro Quadrático Médio Raiz (RMSE).

Os resultados mostraram que os dois modelos, o econométrico ARIMA e o de aprendizado profundo (DL), possuem uma eficácia significativa para previsões de demanda de medicamentos, onde em conjunto podem oferecer uma maior precisão nas previsões, resultado demonstrado com o uso dos critérios definidos. No entanto, a solução apresenta limitações como a ausência de análise de sensibilidade nos parâmetros de entrada e a não avaliação da robustez dos modelos frente a perturbações nos dados de entrada. O presente trabalho diferencia-se por fazer uso de uma base pública, a qual será tratada para resultar em um grupo de medicamentos essenciais para o sistema de saúde, e por aplicar testes nos parâmetros de entrada para avaliar como o modelo de aprendizagem de máquina se comporta frente a essas variações.

2.3.2 Trabalho 2: Predictive Data Analysis: Leveraging RNN and LSTM Techniques for Time Series Dataset

([Agarwal et al. \(2024\)](#)) abordou o problema de prever valores futuros de cotações no mercado de ações. Para resolvê-lo, os autores propuseram utilizar Redes Neurais Recorrentes (RNN) e Memória de Longo Prazo (LSTM) para gerar previsões a partir de um conjunto de dados, superando o problema do desvanecimento do gradiente com o uso da arquitetura LSTM. A metodologia utilizada foi estruturar a solução em módulos e classes, sendo eles:

- Módulo de pré-processamento de dados: inclui as funções para carregar, limpar e normalizar os dados relativos aos preços das ações;
- Módulo de arquitetura do modelo: inclui as funções para construir os modelos RNN e LSTM;
- Módulo de treino: inclui as funções para treinar os modelos com base nos dados históricos;
- Módulo de previsão: inclui as funções para efetuar previsões sobre os dados de teste e avaliar o desempenho dos modelos.

Para construir os modelos, os autores utilizaram Python e as bibliotecas Keras e TensorFlow. Para normalizar os dados, foi utilizado o `MinMaxScaler` da biblioteca `sklearn`. A separação dos conjuntos de treino e teste foi de 85:15, ou seja, 85% dos dados foram utilizados para treinar o modelo LSTM e 15% para teste, com janelas de 100 pontos de dados. O Erro Quadrático Médio Raiz (RMSE), as medidas R-quadrado e as métricas de acurácia foram utilizados para avaliar o desempenho dos modelos.

Os resultados mostraram que o modelo LSTM apresentou desempenho superior ao modelo RNN: o modelo RNN, após 100 épocas, obteve uma acurácia de 97,12% nos dados de treino e de 81,01% nos dados de teste, enquanto o modelo LSTM, aplicado ao mesmo conjunto de dados, alcançou 98,10% nos dados de treino e 91,97% nos dados de teste. No entanto, assim como o trabalho anterior, a solução apresenta limitações como a ausência de análise de sensibilidade nos parâmetros de entrada, a não avaliação da robustez dos modelos frente a perturbações nos dados e a aplicação restrita ao domínio financeiro, sem contemplar contextos hospitalares. O presente trabalho diferencia-se por aplicar métodos de análise de sensibilidade e avaliação da robustez em um modelo preditivo voltado à gestão de estoques hospitalares críticos.

2.3.3 Trabalho 3: Performance analysis of neural network architectures for time series forecasting: A comparative study of RNN, LSTM, GRU, and hybrid models

(Yunita et al. (2025)) abordou o problema de avaliar o desempenho de nove arquiteturas de redes neurais para previsão de séries temporais, nomeadamente RNN, LSTM, GRU, RNN-LSTM, RNN-GRU, LSTM-RNN, GRU-RNN, LSTM-GRU e GRU-LSTM. Para resolvê-lo, os autores propuseram uma avaliação baseada no método de Monte Carlo (MC), com o objetivo de garantir a confiabilidade dos resultados frente à variabilidade decorrente da inicialização aleatória dos pesos. A metodologia utilizada consistiu em selecionar três conjuntos de dados nas áreas da astronomia, cuidados de saúde e maquinaria, realizar uma análise exploratória de dados (EDA) como etapa preliminar de avaliação estatística e de qualidade, implementar as diferentes arquiteturas de redes neurais e, por fim, avaliar os modelos por meio de 100 iterações de Monte Carlo, utilizando as métricas de Erro Absoluto Médio (MAE), Erro Percentual Absoluto Médio (MAPE) e Erro Quadrático Médio (RMSE).

Os resultados mostraram que, pelo teste de Friedman, não houve diferença estatisticamente significativa entre as arquiteturas avaliadas. Esse resultado pode ter sido influenciado por fatores como a dimensão limitada da amostra, com apenas três conjuntos de dados para avaliação, e o possível mascaramento das diferenças de desempenho pelo ruído experimental. Ainda assim, os padrões de desempenho consistentes observados em todos os conjuntos de dados sugerem potenciais vantagens práticas para as arquiteturas híbridas baseadas em LSTM, especialmente as configurações LSTM-RNN e LSTM-GRU. No entanto, a solução apresenta limitações como o número reduzido de conjuntos de dados utilizados na avaliação, a ausência de investigação sobre o impacto de perturbações nos parâmetros de entrada sobre o desempenho preditivo e a não aplicação dos modelos em contextos hospitalares. O presente trabalho diferencia-se por aplicar uma análise de sensibilidade sistemática nos parâmetros de entrada de um modelo LSTM voltado à previsão de estoques hospitalares

críticos, investigando como variações nesses parâmetros afetam o desempenho preditivo, parte não explorada por (Yunita et al. (2025)), que avaliam a robustez apenas em relação à inicialização aleatória dos pesos, sem considerar perturbações nos dados de entrada.

Uma tabela comparativa ajuda a sintetizar as diferenças entre os trabalhos:

Tabela 1 – Comparação entre trabalhos relacionados

Critério	Trabalho 1	Trabalho 2	Trabalho 3	Este trabalho
Objetivo	Previsão de demanda farmacêutica	Previsão de cotações de ações	Comparação de arquiteturas RNN, LSTM e GRU	Análise de sensibilidade de LSTM para estoque hospitalar crítico
Tecnologia	ARIMA + DL (MLOps)	RNN + LSTM (Keras/TensorFlow)	RNN, LSTM, GRU, modelos híbridos	LSTM + análise de sensibilidade
Validação	MAE, MSE, RMSE, AIC, BIC	RMSE, R ² , acurácia	MAE, MAPE, RMSE (Monte Carlo)	[método]
Limitação	Sem análise de sensibilidade	Sem análise de sensibilidade; domínio financeiro	Poucos datasets; sem perturbações na entrada	—
Metricas	AIC, BIC, HQIC, MAE, MSE e RMSE	RMSE	MAE, MAPE e RMSE	MAE, MAPE e RMSE

Fonte: Elaborado pelo autor (2025)

3 Desenvolvimento

Neste capítulo, apresenta-se a solução proposta para o problema identificado, bem como o cronograma de trabalho previsto para o desenvolvimento completo do projeto no TCC2.

3.1 Solução proposta

Descreva detalhadamente a solução que será desenvolvida para resolver o problema apresentado na introdução. A descrição deve incluir:

- **Visão geral da solução:** o que será desenvolvido (sistema, aplicativo, modelo, ferramenta, etc.);
- **Arquitetura:** como os componentes da solução se organizam e interagem;
- **Tecnologias e ferramentas:** quais linguagens, frameworks, bibliotecas, bancos de dados e ambientes serão utilizados, e por que foram escolhidos;
- **Funcionalidades principais:** o que a solução fará para atender aos objetivos;
- **Metodologia de desenvolvimento:** qual abordagem será utilizada (ágil, cascata, prototipação, etc.);
- **CrITÉrios de validação:** como será medido o sucesso da solução (métricas, testes, avaliação com usuários, etc.).

Utilize diagramas, fluxogramas ou mockups para ilustrar a solução. Exemplo de descrição de arquitetura:

A solução proposta consiste em uma aplicação web composta por três camadas: front-end desenvolvido em React.js, back-end em Node.js com Express, e banco de dados PostgreSQL. A comunicação entre front-end e back-end será feita por meio de uma API REST.


3.2 Cronograma de trabalho

O cronograma a seguir apresenta, no formato de diagrama de Gantt, as atividades previstas para o desenvolvimento do TCC2, distribuídas ao longo das semanas do semestre.

Instruções para personalização do cronograma:

- Ajuste o número de semanas conforme o calendário acadêmico do semestre;
- Modifique as atividades de acordo com as etapas do seu projeto;

Figura 1 – Cronograma de atividades – Diagrama de Gantt



Fonte: Elaborado pelo autor (2025)

- Os marcos (*milestones*) indicam entregas importantes — adapte-os às datas de avaliação;
- As setas entre atividades indicam dependências — uma atividade só inicia após a conclusão da anterior;
- Utilize o diagrama como ferramenta de acompanhamento: atualize-o a cada reunião com o orientador.

Referências

- AGARWAL, H. et al. Predictive data analysis: Leveraging rnn and lstm techniques for time series dataset. *Procedia Computer Science*, v. 235, p. 979–989, 2024. ISSN 1877-0509. International Conference on Machine Learning and Data Engineering (ICMLDE 2023). Disponível em: <<https://www.sciencedirect.com/science/article/pii/S1877050924007695>>. 5, 13
- BARÁTH, Z.; VERES, P.; BÁNYAI, A. Beyond traditional forecasting methods: Evaluating LSTM performance on diverse time series. *Mathematics*, v. 14, n. 5, p. 838, 2026. ISSN 2227-7390. Disponível em: <<https://www.mdpi.com/2227-7390/14/5/838>>. 5, 10
- CHIARETTO, S. Um estudo sobre os impactos da gestão de estoques nas instituições hospitalares. *Revista Científica Faculdade Unimed*, 2021. 4
- DIAS, P. S. F. F. e William de S. Previsão de demanda: Ferramenta auxiliadora na tomada de decisão no processo de aquisição de insumos em uma farmácia hospitalar localizada em palmas-to. *humanidadesinovacao*, 2024. 4
- FIALHO, T. Previsibilidade e precisão: Ia na gestão logística da saúde. *medicinasa*, 2025. 4
- GUAN, H. *Assessing Simplification Levels in Neural Networks: The Impact of Hyperparameter Configurations on Complexity and Sensitivity*. 2024. ArXiv preprint arXiv:2409.16086. Acesso em: 11 maio 2026. Disponível em: <<https://arxiv.org/abs/2409.16086>>. 10
- HOCHREITER, S.; SCHMIDHUBER, J. Long short-term memory. 1997. 9
- LAND, C. L. de Souza e M. Estratégias de gestão de estoque hospitalar em organizações públicas no brasil: Um estudo de caso. *Revista de Administração Hospitalar e Inovação em Saúde (RAHIS)*, v. 17, n. 3, 2021. 8
- NOVELLO, P. et al. *Goal-Oriented Sensitivity Analysis of Hyperparameters in Deep Learning*. 2022. ArXiv preprint arXiv:2207.06216. Acesso em: 11 maio 2026. Disponível em: <<https://arxiv.org/abs/2207.06216>>. 10
- RUMELHART, D. E.; HINTON, G. E.; WILLIAMS, R. J. Learning representations by back-propagating errors. *Nature*, 1986. 8
- SEN, D. Explainable deep learning for time series analysis: Integrating SHAP and LIME in LSTM-based models. *Journal of Information Systems Engineering and Management*, v. 10, p. 412–423, 3 2025. 10
- SEYEDAN, M.; MAFAKHERI, F.; WANG, C. Order-up-to-level inventory optimization model using time-series demand forecasting with ensemble deep learning. *Supply Chain Analytics*, v. 3, p. 100024, 2023. ISSN 2949-8635. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S2949863523000237>>. 9

Sierra Espinel, A. I.; Suarez Barón, M. J. Applying deep learning and forecasting techniques to the pharmaceutical supply chain. *Procedia Computer Science*, v. 253, p. 2791–2800, 2025. ISSN 1877-0509. 6th International Conference on Industry 4.0 and Smart Manufacturing. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S1877050925003461>>. 5, 8, 12

WANG, Z. *Validation, Robustness, and Accuracy of Perturbation-Based Sensitivity Analysis Methods for Time-Series Deep Learning Models*. 2024. ArXiv preprint arXiv:2401.16521. Acesso em: 11 maio 2026. Disponível em: <<https://arxiv.org/abs/2401.16521>>. 10

YUNITA, A. et al. Performance analysis of neural network architectures for time series forecasting: A comparative study of rnn, lstm, gru, and hybrid models. *MethodsX*, v. 15, p. 103462, 2025. ISSN 2215-0161. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S2215016125003073>>. 14, 15